

Министерство образования и науки Российской Федерации

Московский государственный университет имени М. В. Ломоносова
Кафедра "Большие данные: инфраструктуры и методы решения задач"

**МЕТОДЫ ДЕТЕКТИРОВАНИЯ АНОМАЛИЙ ПРИ РАБОТЕ
МЕХАНИЧЕСКИХ УСТРОЙСТВ**

(выпускная квалификационная работа магистра)

Выполнил:

студент М121 группы

Кенигсбергер Г. А.

Научный руководитель:

к.т.н. Ступников С. А.

Москва 2021

Аннотация

Основной целью данной работы является изучения существующих методов детектирования аномалий при работе механических устройств по аудиозаписям. Задача была предложена в рамках челленджа по детектированию и классификации акустических сцен и событий DCASE2021.

В рамках поставленной задачи были получены следующие результаты:

- были изучены популярные методы детектирования аномалий звуковых сцен
- были рассмотрены методы решения поставленной задачи в условиях смещенного домена

Оглавление

	Страница
1 Введение	4
1.1 Мотивация	4
1.2 Постановка задачи	4
1.3 Датасет	5
1.4 Условия соревнования	6
2 Методы решения	7
2.1 Решение на основе автоэнкодеров	7
2.2 Решение, использующее CNN	9
2.3 Масочные автоэнкодеры	10
2.4 Автоэнкодеры глубокого восприятия	10
2.5 Ансамбли решений	10
3 Условия смещенного домена	11
3.1 Адаптация существующих решений к условиям смещенного домена . . .	11
4 Практическая часть	12
4.1 Реализованные решения	12
5 Полученные результаты	13

Обозначения

TN	True-negative
FN	False-negative
FP	False-positive
TP	True-positive
CNN	Сверточная нейронная сеть

1 Введение

В данной статье рассказывается о проблеме детектирования аномалий в звуковых сценах при различных условиях. В начале работы описывается текущее положение дел в этой отрасли, перечисляются основные методы решения родственных задач. Задача опубликована в рамках воркшопа по детектированию и классификации акустических сцен и событий DCASE. Вместе с данным воркшопом каждый год проводится одноименный челлендж, на котором можно предложить свое решение поставленной задачи.

1.1 Мотивация

Задача детектирования аномалий при работе механических устройств в различных условиях как никогда актуальна в современных условиях быстроразвивающегося мира. Решение проблемы может быть использовано на производствах, где одновременно работают десятки тысяч одинаковых устройств, так и в автономных системах при создании средств мониторинга состояния устройств.

1.2 Постановка задачи

DCASE челлендж проводится каждый год. К решению предлагаются несколько актуальных задач из области детектирования и классификации акустических сцен и событий. Часть задач переходят из года в год с небольшими изменениями условий, отражающими недостатки прошлогодних решений. В руководящую группу челленджа входят исследователи из Google, профессора из университетов Tampere University, New York University и т.д. Задача по детектированию аномалий звуковых сцен при работе механических устройств была представлена на DCASE2020. На DCASE2021 в задачу было внесено требование устойчивости решения к смещенному домену - алгоритм должен показывать хороший результат в нетипичных условиях окружающей среды: условиях, отсутствующих в обучающем датасете. Кроме того, не должно быть большой деградации при работе в обычных условиях. В реальном мире, поломки устройств слу-

чаются довольно редко и звуковые фрагменты аномальной работы при этом могут быть совершенно разными (например, в зависимости от тяжести поломки), поэтому примеры неправильной работы устройства довольно сложно собрать специально. Исходя из этого, в исходном датасете представлены только примеры нормальной работы устройства, а примеры аномальной работы не представлены вовсе.

- Формулировка первой части задачи: детектирование аномального поведения устройства при условии, что только нормальное поведение представлено в тренировочном датасете.
- Вторая часть задачи (которая как раз является усложнением в этом году) является первой задачей с дополнительным условием: акустические характеристики при обучении и тестировании различны. То есть в тренировочном датасете представлены звуковые записи с некоторыми фиксированными параметрами работы устройств (скорости работы машин, окружающие шумы, определенной нагрузки машин), а в тестовой выборке эти параметры могут быть различными.

1.3 Датасет

В датасете представлены записи звучания следующих устройств: вентилятор, коробка передач, насос, игрушечная машина, игрушечный поезд, клапан и рельсовый доводчик, каждый из звуковых фрагментов имеет длину 10 секунд. Данные в датасете сгруппированы по типу устройства и по типу условий, в которых работает это устройство. К примеру, для вентилятора в одной части данных меняется напряжение сети, а в другой меняется скорость работы. Пара (устройство, тип условий) образует "секцию" в терминах соревнования. При этом тренировочный датасет является крайне несбалансированным по условиям:

- 1000 клипов в секции - это нормальные условия (для вентилятора это может быть работа при нормальных скоростях)
- 3 клипа - это смещенные условия (например, работа вентилятора в турбо-режиме)
- Алгоритм должен быть приспособлен к смещенным условиям, но в то же время нужно избегать деградации при обычных условиях

1.4 Условия соревнования

На рисунке 1.1 представлена схема соревнования. Для каждого из объектов тестовой выборки необходимо вернуть вероятность anomaly score - величину уверенности алгоритма в том, что объект является аномальным. Ключевой метрикой соревнования является roc auc, которая будет вычисляться на основании anomaly score.

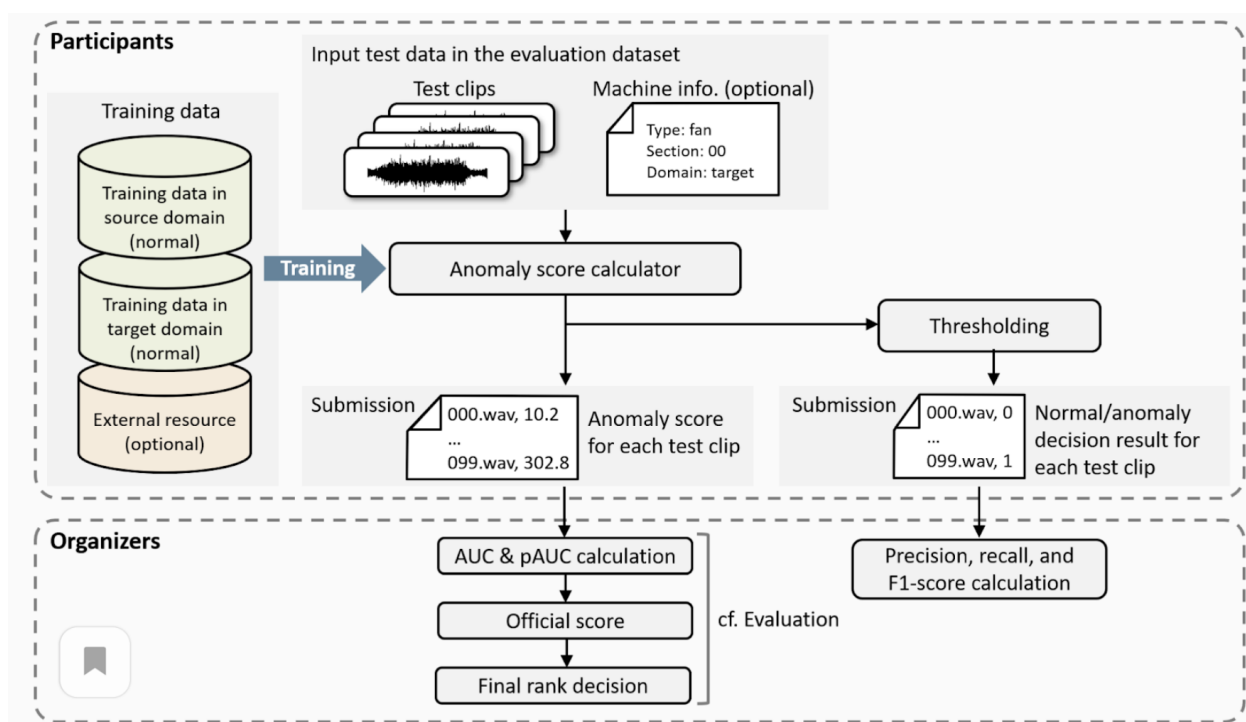


Рис. 1.1: Постановка задачи

2 Методы решения

Методы анализа аномалий можно разбить на три класса по типу данных с которыми они работают:

- Supervised (обучение с учителем) - размечены и аномальный и нормальный классы
- Semi-supervised (обучение с частичным привлечением учителя) - размечен только нормальный из классов
- Unsupervised (обучение без учителя) - данные не размечены вовсе

Поставленная задача относится ко второму типу - semi-supervised, поскольку в выборке присутствуют только объекты нормальных классов.

В данной части рассматриваются существующие методы решения задач детектирования аномалий в аудио. Глобально основные подходы делятся на два типа:

- Методы, использующие автоэнкодеры
- Классификаторы на основе CNN

2.1 Решение на основе автоэнкодеров

Автоэнкодер - это сверточная нейронная сеть специальной архитектуры, позволяющая применять обучение без учителя при использовании метода обратного распространения ошибки. Любой автоэнкодер состоит из двух частей:

- Энкодера, который преобразует входные данные в промежуточное представление. Энкодер аппроксимирует функцию, которая ставит в соответствие входным данным в полноразмерной системе координат, данные в системе координат более низкой размерности.
- Декодера, задача которого восстановить исходные по промежуточному представлению.

Метрика, отражающая разницу между реконструированным результатом и оригинальным представлением называется ошибкой реконструкции.

В процессе обучения автоэнкодера минимизируется ошибка реконструкции. Благодаря тому, что промежуточные слои нейронной сети имеют более низкую размерность, чем оригинальные вход и выход, при преобразовании имеет место потеря информации. За счет этого нейронная сеть учится воспроизводить наиболее эффективное промежуточное представление, запоминает особенности структуры входных данных.




Рис. 2.1: Постановка задачи

На рисунке 2.1 представлена архитектура автоэнкодера. Промежуточные слои часто называют скрытыми или латентными слоями, а промежуточное представление объекта - латентным.

Существует несколько вариантов использования автоэнкодеров:

- Например, автоэнкодер можно использовать для извлечения признаков (feature extraction). Идея заключается в том, чтобы использовать промежуточное (латентное) представление в качестве нового вектора признаков более низкой размерности.
- Зачастую автоэнкодеры используют в задачах классификации и задачах детекти-

рования аномалий. В этом случае в качестве anomaly score (уверенности классификатора в том, что перед ним аномальный объект) используется ошибка реконструкции (reconstruction error) на этом объекте.

После того как автоэнкодер обучился на данном входном распределении объектов, декодер выучился выдавать объекты из этого же распределения. Поэтому, если на вход автоэнкодеру подать аномальный объект, то декодер все равно вернет объект близкий к нормальному распределению, а значит получится большая ошибка реконструкции на данном аномальном объекте.

В статье¹ описан метод детектирования аномалий механических устройств с помощью автоэнкодеров. Anomaly score рассчитывается как ошибка реконструкции наблюдаемого звукового сэмпла. Автоэнкодер обучается на неаномальных данных при минимизации ошибки реконструкции. Сперва вычисляется спектрограмма Мела входного сигнала $X = \{X_t\}_{t=1}^T$, где T - количество фреймов во входном сигнале. Далее спектрограммы Мела объединяются в окна по P фреймов в каждом окне и в таком виде подаются на вход автоэнкодеру. Архитектура автоэнкодера состоит из полносвязного входного слоя, трех скрытых полносвязных слоев и полносвязного выходного слоя. После каждого слоя используется функция активации ReLU. Ошибка реконструкции вычисляется следующим образом: $A_\theta(X) = \frac{1}{DT} \sum_{t=1}^T \|\psi_t - r_\theta(\psi_t)\|_2^2$

Для определения аномального порога делается предположение, что ошибка реконструкции на тренировочном датасете имеет гамма-распределение, а за аномальный порог берется 90-й процентиль данного распределения.

2.2 Решение, использующее CNN

Еще одно семейство решений данной задачи объединяет методы, основанные на машинной идентификации. Модель обучается идентифицировать секцию, которой принадлежит наблюдаемый фрагмент. Секция сигнала - это группа сигналов для фиксированного типа устройства при фиксированных условиях.

Нейронная сеть выдает softmax значения, которые являются вероятностями принадлежности сигнала той или иной секции. Anomaly score вычисляется как отрицательный логит ответа сети для корректного класса. Авторы статьи² предлагают использо-

¹Yuma Koizumi Noboru Harada Daisuke Niizumi Kota Dohi Ryo Tanabe Harsh Purohit Takashi Endo Yohei Kawaguchi Keisuke Imoto. "Unsupervised anomalous sound detection for machine condition monitoring under domain shifted conditions". в: <https://arxiv.org/pdf/2106.04492.pdf> (2021), с. 1.

²там же, с. 1.

вать нейронную сеть MobileNetV2 - сверточную нейронную сеть, требующую значительно меньших мощностей для обучения по сравнению с аналогами.

2.3 Масочные автоэнкодеры

Рассказать про MADE³ и их применение в задачах детектирования аномалий.⁴

2.4 Автоэнкодеры глубокого восприятия

Рассказать про автоэнкодеры глубокого восприятия в задачах детектирования аномалий.⁵

2.5 Ансамбли решений

Рассказать про ансамбли решений в челлендже прошлого года.⁶

³Iain Murray Hugo Larochelle Mathieu Germain Karol Gregor. “MADE: Masked Autoencoder for Distribution Estimation”. в: <https://arxiv.org/pdf/1502.03509.pdf> (2015), с. 1.

⁴Fangzhou Cheng Ritwik Giri Srikanth V. Tenneti. “Unsupervised anomalous sound detection using self-supervised classification and group masked autoencoder for density estimation”. в: http://dcase.community/documents/challenge2020/technical_reports/DCASE2020_Giri103t2.pdf (2020), с. 1.

⁵Irina Fedulova Heinrich Schulz Dmitry V. Dylov Nina Tuluptceva Bart Bakker. “Anomaly Detection with Deep Perceptual Autoencoders”. в: <https://arxiv.org/pdf/2006.13265.pdf> (2020), с. 1.

⁶Ritwik Giri, “Unsupervised anomalous sound detection using self-supervised classification and group masked autoencoder for density estimation”, указ. соч., с. 1.

3 Условия смещенного домена

3.1 Адаптация существующих решений к условиям смещенного домена

Рассказать, как можно адаптировать ранее описанные методы к смещенным условиям, как при этом минимизировать деградацию качества на несмещенных условиях.

4 Практическая часть

4.1 Реализованные решения

Пока что я только запустил baseline решения, описанные в статье.¹

¹Yohei Kawaguchi, “Unsupervised anomalous sound detection for machine condition monitoring under domain shifted conditions”, указ. соч., с. 1.

5 Полученные результаты

Список литературы

Mathieu Germain Karol Gregor, Iain Murray Hugo Larochelle. “MADE: Masked Autoencoder for Distribution Estimation”. в: <https://arxiv.org/pdf/1502.03509.pdf> (2015).

Nina Tuluptceva Bart Bakker, Irina Fedulova Heinrich Schulz Dmitry V. Dylov. “Anomaly Detection with Deep Perceptual Autoencoders”. в: <https://arxiv.org/pdf/2006.13265.pdf> (2020).

Ritwik Giri Srikanth V. Tenneti, Fangzhou Cheng. “Unsupervised anomalous sound detection using self-supervised classification and group masked autoencoder for density estimation”. в: http://dcase.community/documents/challenge2020/technical_reports/DCASE2020_Giri103_t2 (2020).

Yohei Kawaguchi Keisuke Imoto, Yuma Koizumi Noboru Harada Daisuke Niizumi Kota Dohi Ryo Tanabe Harsh Purohit Takashi Endo. “Unsupervised anomalous sound detection for machine condition monitoring under domain shifted conditions”. в: <https://arxiv.org/pdf/2106.04492.pdf> (2021).